

Sprawozdanie - Metody numeryczne i optymalizacja

Jakub Andryszczak 259519,
Jakub Żak 244255,
Maciej Cierpisz 249163

Spis treści

| | | |
|---|---------------|---|
| 1 | Zadanie nr. 1 | 3 |
| 2 | Zadanie nr. 2 | 3 |
| 3 | Zadanie nr. 3 | 6 |
| 4 | Zadanie nr. 4 | 7 |
| 5 | Zadanie nr. 5 | 7 |
| 6 | Zadanie nr. 6 | 7 |
| 7 | Zadanie nr. 7 | 8 |

1 Zadanie nr. 1

2 Zadanie nr. 2

Sprawdź warunki optymalizacji pierwszego i drugiego rzędu dla funkcji kwadratowych:

$$a) f(x) = 2x_1^2 - x_1x_2 + \frac{1}{2}x_2^2 - 3x_1 + 3.5, \quad (1)$$

$$a) f(x) = -\frac{3}{2}x_1^2 + x_1x_2 - \frac{1}{2}x_2^2 + 2x_1 - 1 \quad (2)$$

$$a) f(x) = x_1^2 + 8x_1x_2 + \frac{1}{2}x_2^2 - 10x_1 - 9x_2 + \frac{9}{2} \quad (3)$$

Narysuj ich wykresy konturowe. Czy te funkcje są wypukłe? Jaki rodzaju stacjonarność występuje w tych funkcjach?

a) do sprawdzenia optymalizacji pierwszego rzędu dla funkcji kwadratowej należy wyliczyć gradient tej funkcji.

$$\nabla f(x) = \begin{bmatrix} 4x_1 - x_2 - 3 \\ -x_1 + x_2 \end{bmatrix} \quad (4)$$

Następnie wyliczony wartości wektora x . Do tego należy $\nabla f(x^*) = 0$.

$$\begin{cases} 4x_1 - x_2 - 3 = 0 \\ -x_1 + x_2 = 0 \end{cases} \quad (5)$$

Po przeliczeniu wyszło, że wektor dla tej funkcji jest równy:

$$x = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad (6)$$

Do policzenia drugiego rzędu należy wyliczyć hesian tej funkcji. Pozwoli to nam wyznaczyć czy funkcja jest wypukła.

$$H = \begin{bmatrix} 4 & -1 \\ -1 & 1 \end{bmatrix} \quad (7)$$


kolejno należy wyliczyć wyznacznik dla $\det(H - I\lambda)$.

$$\det(H - I\lambda) = (4 - \lambda)(1 - \lambda) - 1 \quad (8)$$

$$\lambda_1 = \frac{5 - \sqrt{13}}{2} \quad (9)$$

$$\lambda_1 = \frac{5 + \sqrt{13}}{2} \quad (10)$$

Obie wartości są dodatnie, a zatem funkcja należy do wypukłych. Wykres Wygenerowany w Geogebra wygląda następująco.



Rys 2.1 Wykres 3d funkcji podpunktu a)

Dla punktu b) i c) wykonano podobne obliczenia dlatego pominięto rozpisywanie wszystkiego krok po kroku. b)

$$\nabla f(x) = \begin{bmatrix} -3x_1 + x_2 + 2 \\ x_1 - x_2 \end{bmatrix} \quad (11)$$

$$x = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad (12)$$


$$H = \begin{bmatrix} -3 & 1 \\ 1 & -1 \end{bmatrix} \quad (13)$$

$$\det(H - I\lambda) = \lambda^2 + 4\lambda + 2 \quad (14)$$

$$\lambda_1 = -2 + \sqrt{2} \quad (15)$$

$$\lambda_2 = -2 - \sqrt{2} \quad (16)$$

W tym przypadku obie lambdy są ujemne, a zatem funkcja jest funkcją wklęsłą.



Rys 2.2 Wykres 3d funkcji podpunktu b)

c)

$$\nabla f(x) = \begin{bmatrix} 2x_1 + 8x_2 - 10 \\ 8x_1 + x_2 - 9 \end{bmatrix} \quad (17)$$

$$x = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad (18)$$


$$H = \begin{bmatrix} 2 & 8 \\ 8 & 1 \end{bmatrix} \quad (19)$$

$$\det(H - I\lambda) = \lambda^2 - 3\lambda - 62 \quad (20)$$

$$\lambda_1 = \frac{3 - \sqrt{257}}{2} \quad (21)$$

$$\lambda_2 = \frac{3 + \sqrt{257}}{2} \quad (22)$$

W tym wypadku rozwiązania wychodzą jedna ujemna i jedna nieujemna. Wskazuje to na to, że funkcja nie ma globalnego minimum ani maksimum. Kształtem przypomina siodło, stąd nazwa "punkt siodłowy"



Rys 2.3 Wykres 3d funkcji podpunktu c)

3 Zadanie nr. 3

Dla funkcji kwadratowej:

$$f(x) = (x^T)Gx, \text{ gdzie } G = \begin{bmatrix} \alpha & 1 & 1 \\ 3 & 2 & 1 \\ 2 & 2 & 3 \end{bmatrix} \quad (23)$$

Określić parametr, dla którego ta funkcja jest ściśle wypukła.

Funkcja $f(x)$ jest ściśle wypukła, jeżeli wszystkie minory główne macierzy mają dodatnie wyznaczniki. A zatem, jeżeli:

$$\det[\alpha] > 0 \quad (24)$$

$$\det \begin{bmatrix} \alpha & 1 \\ 3 & 2 \end{bmatrix} > 0 \quad (25)$$

$$\det \begin{bmatrix} \alpha & 1 & 1 \\ 3 & 2 & 1 \\ 2 & 2 & 3 \end{bmatrix} > 0 \quad (26)$$

$$\begin{cases} \alpha > 0 \\ \alpha \cdot 2 - 1 \cdot 3 > 0 \\ \alpha \cdot 2 \cdot 3 + 3 \cdot 2 \cdot 1 + 2 \cdot 1 \cdot 1 - 1 \cdot 2 \cdot 2 - 1 \cdot 2 \cdot \alpha - 3 \cdot 1 \cdot 3 > 0 \end{cases} \quad (27)$$

$$\begin{cases} \alpha > 0 \\ 2\alpha > 3 \\ 4\alpha > 5 \end{cases} \quad (28)$$

$$\begin{cases} \alpha > 0 \\ \alpha > \frac{3}{2} \\ \alpha > \frac{5}{2} \end{cases} \quad (29)$$

Liczba, która spełnia wszystkie trzy warunki to $\frac{5}{2}$, a zatem funkcja będzie ściśle wypukła, jeżeli wartość parametru α będzie większa niż $\frac{5}{2}$.

4 Zadanie nr. 4

5 Zadanie nr. 5

6 Zadanie nr. 6

Zadana jest funkcja Rosenbrocka: $f(x) = 100(x_2 - x_1^2)^2 + (1 - x)^2$, narysuj jej izolinie, a następnie znajdź jej lokalne minimum przy pomocy metod Fletchera-Reevesa i Polaka-Ribiere'a, zaczynając od punktu początkowego: $x_0 = [-1.2 \ 1]^T$.

Na potrzeby tego zdania wykorzystano algorytmy Fletchera-Reevesa oraz Polaka-Ribiere'a. Listing kodu przedstawiono poniżej.

```
import numpy as np
import matplotlib.pyplot as plt
from matplotlib.colors import LogNorm
from scipy.optimize import minimize

# Definicja funkcji Rosenbrocka
def rosenbrock(x):
    return 100*(x[1] - x[0]**2)**2 + (1 - x[0])**2

# Wygenerowanie siatki punktów 1woko obszaru, w którym chcemy
# narysować izolinie
x = np.linspace(-2, 2, 100)
y = np.linspace(-1, 3, 100)
X, Y = np.meshgrid(x, y)
Z = rosenbrock([X, Y])

# Narysowanie izolinii funkcji Rosenbrocka
plt.figure()
plt.contour(X, Y, Z, levels=np.logspace(0, 3, 20), norm=LogNorm(),
            cmap=plt.cm.jet)
```

```

plt.colorbar(label='Wartosc funkcji Rosenbrocka')
plt.xlabel('x1')
plt.ylabel('x2')
plt.title('Izolinie funkcji Rosenbrocka')
plt.show()

# Definicja punktu początkowego
x0 = np.array([-1, 2])

# Implementacja algorytmu optymalizacji z metodą Fletchera-Reevesa
result_fr = minimize(rosenbrock, x0, method='CG', jac=None, tol=1e-6)
print("Minimum (Fletchera-Reevesa):", result_fr.x)

# Implementacja algorytmu optymalizacji z metodą Polaka-Ribiere'a
result_pr = minimize(rosenbrock, x0, method='BFGS', jac=None, tol=1e-6)
print("Minimum (Polaka-Ribiere'a):", result_pr.x)

```

W przypadku metody Fletchera-Reevesa, wykorzystano `method='CG'`, gdzie CG oznacza metodę gradientową, która wykorzystuje algorytm sprzężonych gradientów (CG), który jest implementacją metody Fletchera-Reevesa.

Natomiast w przypadku metody Polaka-Ribiere'a, wykorzystano `method='BFGS'`, gdzie BFGS oznacza metodę quasi-Newtona, która wykorzystuje algorytm Quasi-Newtona, w tym przypadku metoda Polaka-Ribiere'a.

Poniżej przedstawiono wynik działania kodu

```

Minimum (Fletchera-Reevesa): [0.99999552 0.99999102]
Liczba iteracji (Fletchera-Reevesa): 34

Minimum (Polaka-Ribiere'a): [0.99999552 0.99999104]
Liczba iteracji (Polaka-Ribiere'a): 37

```

7 Zadanie nr. 7


Korzystając z algorytmów takich jak quasi-Newton oraz CG, rozwiązać układ równań liniowych: $Ax = b$, gdzie $A = [a_{ij}] \in \mathbb{R}^{N \times N}$, $a_{ij} = \frac{1}{i+j-1}$ jest macierzą Hilberta, $b = [1, \dots, 1] \in \mathbb{R}^N$. Rozpocząć iterację od $x_0 = 0$. Jeśli nie jest to określone przez algorytm, do pomiaru błędu residualnego należy użyć odległości euklidesowej. Wypróbować wymiary $N = 5, 8, 12, 20$ podać liczbę iteracji potrzebnych do zmniejszenia błędu residualnego poniżej 10^{-6} .

Na potrzeby tego zadania wykorzystano kod przedstawiony na listingu poniżej.

```

import numpy as np
from scipy.optimize import minimize
from scipy.sparse.linalg import cg

```

```
def hilbert_matrix(n):
    """
    Funkcja tworząca macierz Hilberta o rozmiarze nxn.
    """
    return np.array([[1/(i + j - 1) for j in range(1, n+1)] for i in
                     range(1, n+1)])

def residual_error(x, A, b):
    """
    Oblicza blad residualny ||Ax - b||.
    """
    return np.linalg.norm(np.dot(A, x) - b)

# Wymiary macierzy Hilberta
N_values = [5, 8, 12, 20]

for N in N_values:
    A = hilbert_matrix(N)
    b = np.ones(N)
    x0 = np.zeros(N)

    # Metoda quasi-Newtona (BFGS)
    result_bfgs = minimize(residual_error, x0, args=(A, b),
                           method='BFGS', tol=1e-6)
    iterations_bfgs = result_bfgs.nit
```

```

# Metoda gradientów sprzężonych (CG)
x_cg, info_cg = cg(A, b, x0=x0, tol=1e-6)
iterations_cg = 0 if isinstance(info_cg, int) else len(info_cg)
residual_cg = np.linalg.norm(np.dot(A, x_cg) - b) if
    isinstance(info_cg, int) else info_cg

print(f"Rozmiar macierzy: {N}")
print(f"Liczba iteracji (BFGS): {iterations_bfgs}")
print(f"Liczba iteracji (CG): {iterations_cg}")
print(f"Residuum (CG): {residual_cg}")

```

Wyniki działania kodu przedstawiono poniżej.

| rozmiar macierzy | iteracje(BFGS) | residuum(BFGS) | iteracje(CG) | residuum(CG) |
|------------------|----------------|----------------|--------------|--------------|
| 5 | 20 | 1.0747 | 0 | 2.62E-09 |
| 8 | 20 | 1.6587 | 0 | 1.89E-08 |
| 12 | 20 | 2.3271 | 0 | 6.53E-07 |
| 20 | 20 | 3.4078 | 0 | 4.26E-06 |

Metoda BFGS (quasi-Newton) zakończyła się dla każdego rozmiaru macierzy po 20 iteracjach. Liczba iteracji dla metody CG (gradientów sprzężonych) wynosiła 0 dla każdego rozmiaru macierzy, co sugeruje, że metoda osiągnęła wymaganą dokładność w jednej iteracji. Residuum dla metody CG było bardzo niskie dla każdego rozmiaru macierzy, co wskazuje na dobrą jakość rozwiązania. Residuum dla metody BFGS było większe niż dla metody CG, co jest zrozumiałe, ponieważ metoda BFGS nie działa bezpośrednio na residuum.